雷翔兮 Peter

邮箱：peterlei001123@gmail.com

目标岗位

AI Agent 应用开发工程师｜大模型应用开发工程师 / Tech Lead｜AI FDE（企业 AI 落地）｜AI 产品经理 / 产品负责人

个人优势

- **复杂企业级 AI 编程经验**：具备 3 年 AI Agent、AI 应用与 AI 提效工程经验，长期在多仓库、多角色、多环境的企业级工程项目中使用 Cursor、GitHub Copilot、Codex、Claude Code 等 AI 编程工具完成真实交付。
- **AI 工作流与工程管理**：在团队内推动 AI coding workflow，将 PRD、接口契约、垂直切片、测试门槛、PR review、联调验收和上线风险收口标准化，形成适合人类工程师与 coding agent 协作的项目管理方式。
- **AI 自动化降本增效**：主导公司级 AI 代码 Review 审计平台，将 AI 辅助代码理解、规则审计、提交分析和复核流程接入研发治理，支撑千万级研发费用节省，并验证 AI 在企业工程管理中的实际业务价值。
- **Agent Harness 与 AI Native 应用理解**：在 Darvin 和 BrandNative 项目中持续实践 Agent runtime、MCP / tool calling、多模型网关、RAG / context composer、human-in-the-loop、eval framework、反馈闭环和多模态生成链路。
- **产品思维型工程负责人**：在 Darvin 中同时承担核心技术负责人和产品规划职责，能从用户角色、业务闭环、商业可行性和工程复杂度共同判断优先级，适合 AI 应用 / Agent 平台 / 研发提效方向的复合型岗位。

工作经历

第四范式 | AI Native 应用与平台技术负责人

2024 - 至今

Darvin 去中心化 AI 计算与评测平台 | 实际主责技术负责人

Darvin 是第四范式与 Gradient Network 共同孵化的 AI Infrastructure 项目，目标是把 AI 任务、数据标注、模型评测、K8s 算力调度和链上激励抽象为可复用的通用任务子网。本人承担实际主责技术负责人和产品规划职责，提出并主导 CLI、数据评测平台、子网部署、K8s 运行时和 AI coding workflow 等关键方向，推动项目从 demo 走向可部署、可评测、可运营的工程平台。

- **AI 数据标注与测评平台**：主导构建人机协同的评测数据平台，使用异步任务流、审核流、webhook 回调、短期授权 token、幂等结果拉取和自动打分回流等设计，将人工标注、审核、模型评分和榜单更新串成可追踪的数据闭环。
- **多角色系统架构设计**：围绕任务发布、模型提交、人工标注、结果审核、算力执行和平台运营等角色，设计多租户模型、RBAC 权限控制、身份映射、任务可见性、审计日志和状态机，降低复杂协作场景下的权限与流程耦合。
- **AI Infrastructure 与 K8s 调度**：主导规划并参与实现通用 AI 任务运行时，将 Helm 模板渲染、K8s Job / Deployment 创建、命名空间隔离、Secret 注入、状态同步、sidecar 结果回传和服务 endpoint 暴露抽象为统一部署能力，为训练、评测、推理任务提供底层调度框架。
- **异构算力与国产信创适配**：规划并推进多集群、多硬件后端的统一调度方案，通过节点标签、资源描述、镜像/依赖约束和调度策略适配不同 GPU / NPU / 国产算力环境，使平台具备面向异构算力池扩展的基础架构。
- **去中心化子网部署体系**：主导子网部署 CLI 和标准化操作入口，将配置校验、资产准备、链上注册、后端元数据创建、数据集绑定、任务提交、状态查询和日志查看收敛为可复用流程，降低新子网接入、部署和排障成本。
- **AI Native CLI 与 Agent 操作层**：较早提出并设计面向 Agent 使用的 CLI 体系，将复杂平台能力封装为稳定命令、结构化输出、步骤化报告和可验收结果，为后续通过自然语言 Agent / AI skill 执行部署、任务管理和平台运维打基础。
- **工程质量与 CI/CD 体系**：推动以接口契约、数据库迁移、TDD、单元测试、E2E 验收和远端 CI 为门槛的开发流程，围绕 CLI、backend API、K8s 任务生命周期、webhook / token / result pull 等关键链路建立回归测试和上线检查。
- **AI 编程新范式下的团队协作**：在团队内推动“需求拆解 - 接口契约 - 垂直切片 - AI 辅助编码 - 人工 review - 自动化验收”的协作流程，提升多人和 coding agent 并行开发时的交付稳定性。

关键结果：

- 跑通从任务创建、数据绑定、人工标注、审核、自动评分到结果展示的端到端闭环。
- 多个关键能力合入主线，覆盖多租户权限、人工评测、评测模板部署、K8s 运行时部署、前后端身份映射和公共资产服务等平台能力。
- 将 Darvin 从单点功能开发推进为横跨后端服务、CLI、任务调度引擎、前端、标注平台、K8s 和链上事件的复杂 AI Infrastructure 工程。

公司级 AI 代码 Review 审计平台

独立搭建面向企业研发治理的 AI 代码审计 Agent，将代码提交理解、风险判断、人工复核和管理看板串成自动化工作流。

- **代码审计 Agent 设计**：将 Git commit、diff、文件类型、变更规模、作者信息和历史上下文结构化为 Agent 可消费的上下文，用于理解一次提交的真实意图和影响范围。
- **模型与规则协同**：以 CodeQwen1.5-7B-Chat 这类 7B 级代码模型承担语义摘要、风险解释和复核建议，静态规则与启发式规则承担确定性过滤，降低批量审计中的推理成本。
- **风险决策与复核闭环**：设计风险分级、问题归因和人工确认机制，识别低质量提交、重复性修改、异常大规模变更、疑似无效提交和高风险代码变更。
- **企业级看板与治理视图**：按项目、人员、时间窗口、问题类型和风险等级聚合审计结果，输出可追踪的研发质量看板，辅助管理侧评估有效提交和异常研发行为。
- **工程系统集成**：接入内部代码仓库和工程流水线，支持批量扫描、增量分析、审计报告生成和人工复核状态回写，形成可持续运行的企业级 Agent 应用。

AI 算法部署与异构算力框架

- 负责 AI 算法部署框架建设，帮助算法科学家将模型与算法代码部署到异构国产算力集群及端侧设备。
- 将算法实验代码到生产部署的流程固化为可复用框架，降低不同硬件、不同运行环境下的部署成本和交付风险。
- 与算法科学家协作，将模型服务化、环境依赖、部署脚本、资源约束和运行稳定性沉淀为工程规范。

华为技术有限公司 | AI 大语言模型 / Python / 软件集成工程师

2023.11 - 2024

- **AI for CI/CD 早期实践**：在 2023 年底大模型工程化仍处早期阶段，围绕 5G / LTE 产品版本构建、告警分析和流水线看护，探索 function calling、模型路由、RAG 检索增强和规则引擎结合的工程方案。
- **版本构建与智能告警**：负责 LTE 产品版本集成构建和日常出包流程，使用 Python 自动化版本成本看护、接口变更检查、循环异常和内存变更检查，将版本告警、变更上下文和历史问题库结合，提升异常定位效率。
- **参数资料自动化工作流**：主导无线产品北向参数资料自动化制作工程，将自然语言需求解析、参数模板、资料生成规则和流水线任务编排结合，在华为云龙平台搭建一键式流水线；该流程每年节省约 60 人规模的重复性资料制作与校验投入。
- **RAG 与内部知识工程**：参与构建面向工程问题的知识检索和问答能力，将接口文档、版本记录、问题单、代码规范和构建日志整理为可检索语料，服务于 AI 助手训练数据收集、问题定位和流程自动化。
- **代码规范与质量门禁**：部署代码规范检查门禁，结合传统静态检查工具、规则配置和流水线准入机制，对提交质量、接口变更和潜在风险进行自动化检查。
- **复杂通信产品工程落地**：参与 5G / LTE 产品线算法和工程集成工作，将节能相关算法、参数策略和 AI 辅助判断嵌入大型软硬结合通信系统，积累在复杂工程环境中做自动化、稳定性和算法落地的经验。

元点共振科技 | Python 软件开发工程师

2022.11 - 2023.09

- 使用 Python FastAPI 主导用户微服务开发，设计数据库 schema、登录系统 CRUD，并集成 Google API 获取 Gmail 账户访问权限。
- 创建并打包用户服务 SDK，简化其他服务接入；使用 AWS DynamoDB、S3、Boto3 管理用户元数据、图像和视频数据。
- 使用 GitHub Actions 实现 CI/CD，将服务部署到 AWS Elastic Beanstalk。

个人项目

BrandNative Agent Harness

2026

个人独立设计并实现的多模态 Agent 项目，目标是让 AI 像一个懂品牌的营销助手一样工作：先理解品牌资料，再根据任务自动选择文案、图片、音乐、视频等模型，生成可用于展示的营销素材，并在用户反馈后持续改进。

- **Agent 设计**：将 Agent 设计为“理解任务 - 读取品牌资料 - 调用合适工具 - 检查结果 - 记录反馈”的完整流程，而不是简单聊天机器人；用统一的品牌资料文档记录品牌定位、语气、视觉风格、产品卖点和素材引用。
- **多模态生成能力**：覆盖品牌文案、商品主图、小红书宣传图、品牌 BGM、15 秒竖版广告视频等场景，让同一个品牌助手可以处理文本、图片、音乐、视频和语音/音效任务。
- **多模型协同**：按任务类型调度不同模型，代码和 demo 中配置/预留约 9 个模型通道，包括规划与文案模型、图像模型、视频模型、音乐模型、语音/音效模型和结果评估模型；核心思路是让模型各自负责擅长的环节，而不是用一个大模型解决所有问题。
- **Harness 设计**：搭建统一运行框架，管理任务拆解、模型调用、结果候选、质量检查、错误重试和运行记录，使复杂的多模型生成流程可追踪、可复现、可调试。
- **可演示效果**：Demo 可展示从品牌资料导入、品牌理解生成、营销任务规划、多模型生成素材、结果评分，到用户反馈写回并影响下一轮生成的完整闭环，体现对 AI Agent 产品化和工程落地的理解。

早期项目与实习

Smart Recipes | AI 食材识别与菜谱推荐

2023.01 - 2023.04

- 基于 Flask 构建 Web 应用，使用 AWS Elasticsearch 实现食材到菜谱的复杂搜索与排序。
- 使用 OpenCV、Vision Transformer、Faster R-CNN 做食材识别和菜谱推荐增强。

早期 Java / 后端实习经历

2020.05 - 2022.08

- 在翊森科技使用 Java Spring Boot 设计交易所数据抽取与调度系统，写入 PostgreSQL，并通过 Redis 分布式锁提升 100+ 货币数据处理效率。
- 在上海翊本生物科技构建 Java 库存控制系统，自动化库存跟踪与订单处理，每日节省约 2 小时手工工作。

教育背景

美国俄亥俄州立大学 | 计算机和信息科学学士

2019 - 2023

主修课程：数据结构与算法、面向对象软件工程、机器学习、移动应用开发、计算机视觉、网络安全。